

Projektni prijedlog

Iskra Gašparić, Domagoj Bošnjak

Travanj 2021.

1 Uvod

S obzirom na pojačan razvoj autonomnih vozila i ADAS-a (advanced driver assistance systems) jasna je potreba za kvalitetnom detekcijom prometnih znakova. Glavni fokus ovog rada bit će njihova klasifikacija i to bez korištenja cijelog (relativno velikog) skupa podataka za treniranje.

Skup podataka koji se koristi jest GTSRB skup, koji sadrži preko 50000 slika prometnih znakova. Uz eventualni, generalno preporučeni, *data augmentation*, dolazimo do poprilično velikog broja primjera za treniranje. To je samo po sebi korisno, ali uvjetuje sporu manipulaciju podacima. Dodatno, razumna je pretpostavka da za željenu preciznost nisu nužni svi dani primjeri. Stoga je osim prirodnog zahtjeva točnosti klasifikacije, još jedan cilj ovog rada upravo svojevrsni *data reduction*, odnosno pokušaj odbacivanja dijela primjera iz skupa za treniranje uz minimalan ili nikakav gubitak točnosti. Time bi se zadržali informativni primjeri iz skupa za treniranje, a maknuli oni redundantni, koji potencijalno mogu dovesti do overfittinga i povećanja vremena treniranja. Primjer sličnog postupka i detaljnija motivacija može se pronaći u [1].

Planirana metoda rješavanja glavnog problema jest konvolucijska neuronska mreža, potaknuta dodatno činjenicom da se u top 10 metoda na natjecanju iz kojeg dataset originalno potječe našlo nekoliko konvolucijskih neuronskih mreža. Povrh toga, konvolucijske neuronske mreže pokazale su se izrazito efikasne u području precizne klasifikacije slika.

2 Podatci i značajke


Dataset koji se koristi jest *German Traffic Sign Recognition Benchmark* (nadalje GTSRB) dataset. Skup sadrži 51839 slika prometnih znakova. Dostupan je javno na linku [2]. Na istom linku dostupni su i najbolji radovi na pripadnom natjecanju.



Slika 1: Primjeri slika iz GTSRB dataseta

Znakovi su podijeljeni u 43 klase, predstavljene kao brojevi od 0 do 42. Slike su označene u sljedećem obliku, uz napomenu da je oznaka klase dana isključivo za skup za treniranje:


- Širina
- Visina
- ROI.x1 (x koordinata gornjeg lijevog kuta)
- ROI.y1 (y koordinata gornjeg lijevog kuta)
- ROI.x2 (x koordinata donjeg desnog kuta)
- ROI.y2 (y koordinata donjeg desnog kuta)
- ClassId (oznaka klase)



Slika 2: Primjer oznake slike iz GTSRB dataseta

Uz originalni dataset ponuđeni su primjeri skupova značajki: *HOG features*, *Haar-like features* te *hue histograms*. No, te značajke ponuđene su samo za primjer i njihov broj relativno je malen. Plan je zasigurno koristiti *Haar-like* značajke (značajno više njih te raznovrsnije od originala), a po potrebi i neke druge. Jasno je da je prije detaljnijeg testiranja kvalitete značajki nemoguće unaprijed znati koje značajke su optimalne pa ostavljamo otvorenu opciju korištenja i nekih drugih značajki.

Haar-like značajke, originalno dane u [4], služe za detektiranje raznih uzoraka na slikama. Primjerice vertikalnih i horizontalnih rubova, dijagonala, oblika poput $n \times n$ šahovske ploče i slično. Jedna od njihovih glavnih prednosti jest ta da se nakon jednog računanja tzv. *integralne slike* svaka značajka računa u konstantnom vremenu.



Slika 3: Primjeri računanja Haar-like značajki

Čak i bez korištenja drugih značajki, već samo onih Haar-like, njihov broj i relativna korisnost uvjetuju potrebu za korištenjem *feature selectiona*, odnosno izdvajanja nekih *važnijih* značajki. Pregled aktualnih metoda za odabir značajki u području klasifikacije slika dan je u [3]. Osim toga, korištenje *Boruta* metode opisano je u [5]. Nakon detaljnijeg proučavanja radova i konkretne implementacije nekih od metoda u okviru ovog problema, odabrat ćemo onu koja se pokaže najprikladnijom ili eventualno napraviti usporedbu između više njih.

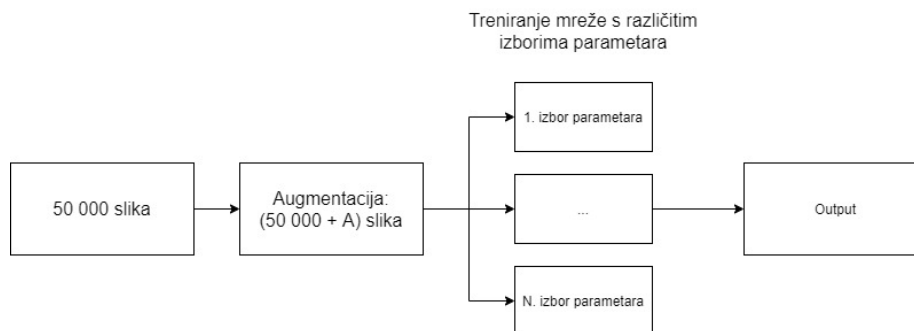
3 Metode

Planirani pristup reduciranju podataka je klasteriranje, konkretno algoritam *k najbližih susjeda*, s obzirom da su podatci označeni. Ideja je napraviti klasteriranje te uzeti određen postotak ili količinu primjera iz svakog klastera, ovisno o situaciji. Glavna evaluacija kvalitete reduciranja podataka bit će upravo točnost mreže te njeno vrijeme treniranja, u usporedbi sa situacijom prije redukcije. No, postoje i mnoge mjere za evaluaciju kvalitete klasteriranja, koje ne ovise o podacima. Koncizan pregled tzv. *internih mjera* kvalitete klasteriranja dan je u [6]. U ovom radu primarno će se koristiti *S_dbw* mjera, detaljnije opisana u [7], dostupna kao vlastiti Python module.

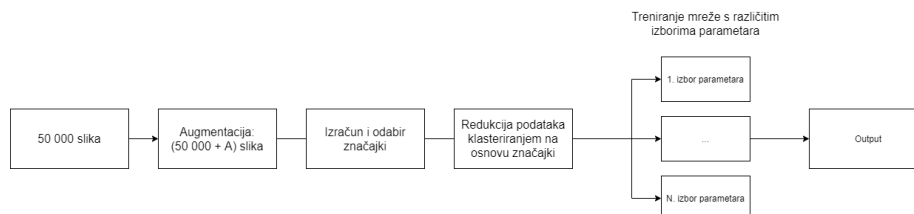
Konačno, metoda rješavanja glavnog problema jest konvolucijska neuronska mreža, s obzirom na to da je problem klasifikacija slika. Generalni konsenzus jest da je kod multi-class klasifikacije korištenjem CNN-a dobar izbor loss funkcije upravo *cross-entropy loss*. Konačno, glavni način evaluacije finalne točnosti jest, jasno, koliko znakova iz skupa za testiranje je točno klasificirano (Train & Test metoda evaluacije modela).

4 Ciljevi i hipoteze

Dvofazni proces reduciranja podataka i treniranja mreže trebao bi se očitovati u smislu efikasnosti, ali potencijalno i preciznosti. Potreba za *fine-tuningom* parametara jasna je u većini algoritmima strojnog učenja; iznimno su male šanse da će prvi izbor varijabilnih parametara biti baš onaj koji trebamo. Bilo da se radi o selekciji značajki, treniranju mreže ili nečemu trećemu, višestruko provođenje procesa s drugim izborom parametrima je vremenski krajnje neefikasno kada radimo na velikom skupu podataka. S druge strane, nasumično micanje podataka iz skupa za treniranje postiglo bi isti cilj u smislu vremena, ali nema apsolutno nikakve garancije da se točnost mreže neće smanjiti, čime bi podešavanje parametara izgubilo smisao. Stoga je finalni cilj postići dovoljno točnu neuronsku mrežu za prepoznavanje prometnih znakova, uz to da mreža ne koristi cijeli originalni skup za treniranje.



Slika 4: Uobičajeni proces



Slika 5: Proces s redukcijom podataka: svaka instanca treniranja mreže je ubrzana, dok se redukcija radi samo jednom

Literatura

- [1] Vighnesh Birodkar Hossein Mobahi Samy Bengio: *Semantic Redundancies in Image-Classification Datasets: The 10% You Don't Need*, 2019.
- [2] [https://benchmark.ini.rub.de/](https://benchmark.ini.rub.de/GTSRB) *GTSRB dataset*
- [3] Verónica Bolón-Canedo, Beatriz Remeseiro, *Feature selection in image analysis: a survey*, 2019.
- [4] Paul Viola, Michael Jones: *Rapid Object Detection using a Boosted Cascade of Simple Features*, 2001.
- [5] Miron B. Kursa, Witold R. Rudnicki: *Feature Selection with the Boruta Package*, JSS Journal of Statistical Software, 2010.
- [6] Yanchi Liu¹, Zhongmou Li, Hui Xiong, Xuedong Gao, Junjie Wu: *Understanding of Internal Clustering Validation Measures*, 2010 IEEE International Conference on Data Mining
- [7] Maria Halkidi, Michalis Vazirgiannis: *Clustering Validity Assessment: Finding the optimal partitioning of a data set*, 2001.